Алгоритмы и Алгоритмические Языки

Семинар #9:

1. Представление строк в памяти.
2. Проверка ввода и программа проверки пароля.
3. Библиотечные функции для работы со строками.
4. Пример утилиты для сортировки строк.

15.10.2024

Представление строк в памяти

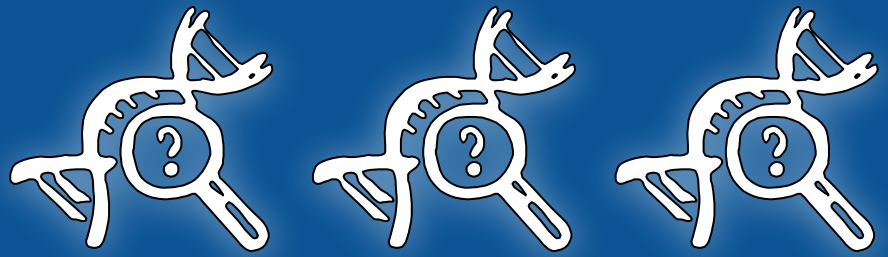

Представление строк в памяти

В языке Си строка – это массив `char`-ов, заканчивающийся нулевым символом (`Null-terminated byte string`):

```c
const char* str = "Hello, world!\n";

printf("%s", str);
```

Представление строки в памяти:

…	04	05	06	07	08	09	0A	0B	0C	0D	0E	0F	10	11	12	…
…	H	e	l	l	o	,		w	o	r	l	d	!	\n	\0	…

Размер строки не учитывает ‘\0’:

```
strlen(“Hello, world!\n”) = 14
```

Кодировка символов в строке

Символы кодируются значениями char-ов по кодировке ASCII:

dec	oct	hex	ch	dec	oct	hex	ch	dec	oct	hex	ch	dec	oct	hex	ch
0	0	00	**NUL** (null)	32	40	20	(space)	64	100	40	@	96	140	60	`
1	1	01	**SOH** (start of header)	33	41	21	!	65	101	41	**A**	97	141	61	**a**
2	2	02	**STX** (start of text)	34	42	22	"	66	102	42	**B**	98	142	62	**b**
3	3	03	**ETX** (end of text)	35	43	23	#	67	103	43	**C**	99	143	63	**c**
4	4	04	**EOT** (end of transmission)	36	44	24	$	68	104	44	**D**	100	144	64	**d**
5	5	05	**ENQ** (enquiry)	37	45	25	%	69	105	45	**E**	101	145	65	**e**
6	6	06	**ACK** (acknowledge)	38	46	26	&	70	106	46	**F**	102	146	66	**f**
7	7	07	**BEL** (bell)	39	47	27	'	71	107	47	**G**	103	147	67	**g**
8	10	08	**BS** (backspace)	40	50	28	(	72	110	48	**H**	104	150	68	**h**
9	11	09	**HT** (horizontal tab)	41	51	29	)	73	111	49	**I**	105	151	69	**i**
10	12	0a	**LF** (line feed - new line)	42	52	2a	*	74	112	4a	**J**	106	152	6a	**j**
11	13	0b	**VT** (vertical tab)	43	53	2b	+	75	113	4b	**K**	107	153	6b	**k**
12	14	0c	**FF** (form feed - new page)	44	54	2c	,	76	114	4c	**L**	108	154	6c	**l**
13	15	0d	**CR** (carriage return)	45	55	2d	-	77	115	4d	**M**	109	155	6d	**m**
14	16	0e	**SO** (shift out)	46	56	2e	.	78	116	4e	**N**	110	156	6e	**n**
15	17	0f	**SI** (shift in)	47	57	2f	/	79	117	4f	**O**	111	157	6f	**o**
16	20	10	**DLE** (data link escape)	48	60	30	**0**	80	120	50	**P**	112	160	70	**p**
17	21	11	**DC1** (device control 1)	49	61	31	**1**	81	121	51	**Q**	113	161	71	**q**
18	22	12	**DC2** (device control 2)	50	62	32	**2**	82	122	52	**R**	114	162	72	**r**

Русские символы – либо `Extended ASCII` (байты с `128` по `255`),
либо многобайтовые символы в кодировке `UTF-8` (см. multibyte strings)!

HSE University

Проверка ввода и программа проверки пароля

Удобный макрос для проверки ввода

```
#define VERIFY_CONTRACT(contract, format, ...) \
    do {                                       \
        if (!(contract)) {                     \
            printf((format), ##__VA_ARGS__);   \
            exit(EXIT_FAILURE);                \
        }                                      \
    } while (0)
```

```
char input_password[MAX_ARRAY_SIZE];

// Считываем пароль от пользователя
int ret = scanf("%s", input_password);
VERIFY_CONTRACT(ret == 1, "ERROR: unable to input string\n");
```

Программа проверки пароля

```
// Условие необходимости проверки пароля
bool check_password = VERIFY_PASSWORD;
char input_password[32U];

// Считываем пароль от пользователя
int ret = scanf("%s", input_password);
VERIFY_CONTRACT(ret == 1, "ERROR: unable to input string\n");

// Проверяем пароль и выполняем соответствующее действие
if (!check_password || password_is_ok(input_password))
{
    printf("Password is OK\n");
}
else
{
    printf("Password is WRONG\n");
}
```

Сравнение строк вручную

```
bool password_is_ok(const char* check)
{
    // Последовательно сравниваем символы обеих строк
    const char* pswd = PASSWORD;
    for (; *pswd != '\0' && *check != '\0'; pswd++, check++)
    {
        if (*pswd != *check)
        {
            // При несовпадении любого символа строки не равны
            return false;
        }
    }

    // В противном случае строки равны при равенстве размеров
    return *pswd == *check;
}
```

Аналоги из стандартной библиотеки – `strcmp` и `memcmp`.

Извлечение пароля из бинарного файла

```
const bool VERIFY_PASSWORD = true;
const char* PASSWORD = "Now you see me!";
```

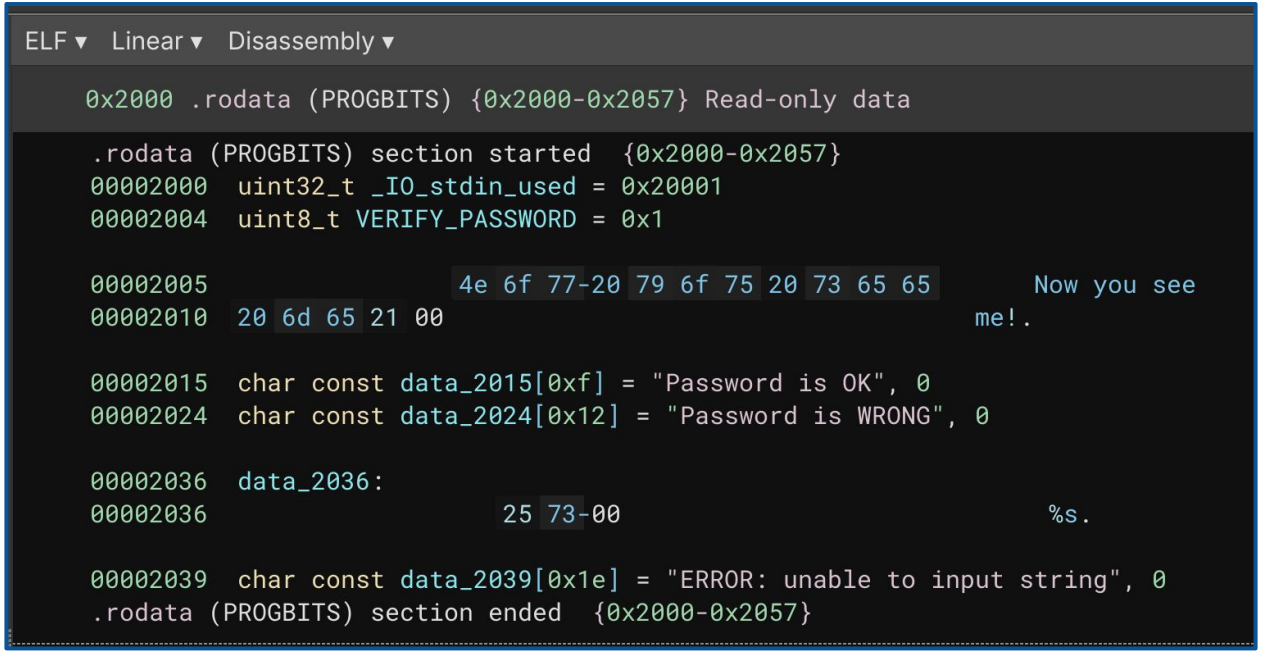

Злонамеренное переполнение буфера

```
❯ printf 01234567890123456789012345678901_123456789ABCDE\\x01 | ./build/password
Password is WRONG
❯ printf 01234567890123456789012345678901_123456789ABCDE\\x00 | ./build/password
Password is OK
❯
```

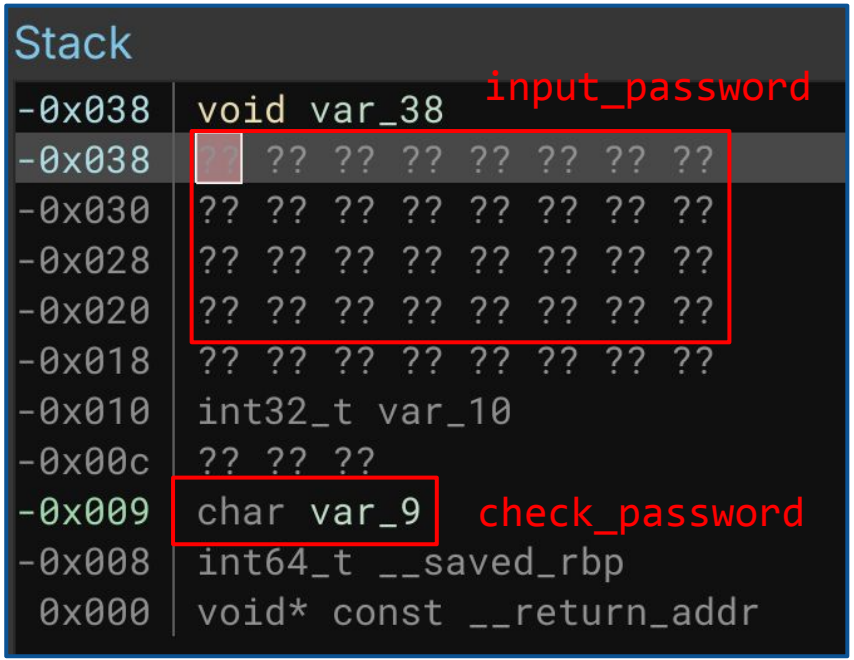

Библиотечные функции для работы со строками

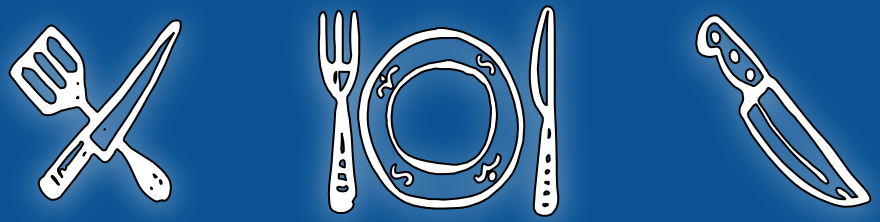

Функции классификации символов

Вот они: isdigit, islower, isupper, isalpha, ...

ASCII values			characters	iscntrl iswcntrl	isprint iswprint	isspace iswspace	isblank iswblank	isgraph iswgraph	ispunct iswpunct	isalnum iswalnum	isalpha iswalpha	isupper iswupper	islower iswlower	isdigit iswdigit	isxdigit iswxdigit
decimal	hexadecimal	octal													
0–8	\x0–\x8	\0–\10	control codes (NUL, etc.)	≠0	0	0	0	0	0	0	0	0	0	0	0
9	\x9	\11	tab (\t)	≠0	0	≠0	≠0	0	0	0	0	0	0	0	0
10–13	\xA–\xD	\12–\15	whitespaces (\n, \v, \f, \r)	≠0	0	≠0	0	0	0	0	0	0	0	0	0
14–31	\xE–\x1F	\16–\37	control codes	≠0	0	0	0	0	0	0	0	0	0	0	0
32	\x20	\40	space	0	≠0	≠0	≠0	0	0	0	0	0	0	0	0
33–47	\x21–\x2F	\41–\57	!"#$%&'()*+,-./	0	≠0	0	0	≠0	≠0	0	0	0	0	0	0
48–57	\x30–\x39	\60–\71	0123456789	0	≠0	0	0	≠0	0	≠0	0	0	0	≠0	≠0
58–64	\x3A–\x40	\72–\100	:;<=>?@	0	≠0	0	0	≠0	≠0	0	0	0	0	0	0
65–70	\x41–\x46	\101–\106	ABCDEF	0	≠0	0	0	≠0	0	≠0	≠0	≠0	0	0	≠0
71–90	\x47–\x5A	\107–\132	GHIJKLMNOP QRSTUVWXYZ	0	≠0	0	0	≠0	0	≠0	≠0	≠0	0	0	0
91–96	\x5B–\x60	\133–\140	[\]^_`	0	≠0	0	0	≠0	≠0	0	0	0	0	0	0
97–102	\x61–\x66	\141–\146	abcdef	0	≠0	0	0	≠0	0	≠0	≠0	0	≠0	0	≠0
103–122	\x67–\x7A	\147–\172	ghijklmnop qrstuvwxyz	0	≠0	0	0	≠0	0	≠0	≠0	0	≠0	0	0
123–126	\x7B–\x7E	\172–\176	{|}~	0	≠0	0	0	≠0	≠0	0	0	0	0	0	0
127	\x7F	\177	backspace character (DEL)	≠0	0	0	0	0	0	0	0	0	0	0	0

Конверсия в/из числовые типы

`atoi/atol/atoll` – преобразование строки в `int, long, long long`.

`strtol/strtoll` – те же конверсии, но с заданным основанием.

`strtof/strtod/strtold` – конверсия строки в `float`, `double`, `long double`.

Обратные преобразования: `strfromf, strfromf, strfromld`

Копирование строк

Копирование строки:

```
char* strcpy(char* dest, const char* src);
```

Копирование строки с учётом размера буфера `dst`:

```
char* strncpy(char* dest, const char* src, size_t count);
```

`Undefined Behavior` в ситуациях:

- Переполнение массива `dest`.
- Наложение массивов `src` и `dest`.
- Отсутствие символа `'\0'` в строке `src`.

Склейка строк

Склейка строк:

```
char* strcat(char* dest, const char* src);
```

Склейка строк с учётом размера буфера `dst`:

```
char* strncat(char* dest, const char* src, size_t count);
```

`Undefined Behavior` в ситуациях:

- Переполнение массива `dest`.
- Наложение массивов `src` и `dest`.
- Отсутствие символа `‘\0’` в строке `src`.

Иные полезные функции

Длина строки:

```
size_t strlen(const char* str);
```

Сравнение строк:

```
int strcmp(const char* lhs, const char* rhs);
```

Токенизация:

```
char* strtok(char* str, const char* delim);
```

Их много!

Пример утилиты для сортировки строк

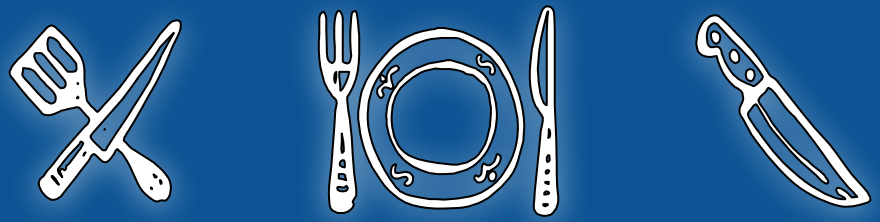

Разбор утилиты сортировки строк

Разбор утилиты sort (см. `09_sort_lines`).

Что стоит учитывать:

- Переполнение буфера при вводе.
- Окончание ввода в программу.
- Пустые строки.
- Символы переноса строки.
- Кусочное считывание строки.

Обработка бинарных данных удобнее!

Применение указателей на функции

```c
int comp_lexicographic(const void* p1, const void* p2)
{
    const char* str1 = *(const char**)p1;
    const char* str2 = *(const char**)p2;

    return strcmp(str1, str2);
}
```

```c
// Выполняем сортировку с заданным компаратором
qsort(lines, num_lines, sizeof(*lines), &comp_lexicographic);
```

Вопросы?

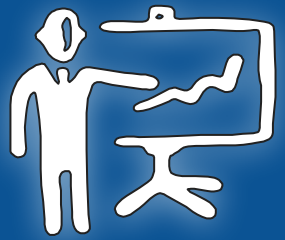

Красивые иконки взяты с сайта handdrawngoods.com